

Udemy 網頁開發課程之商業分析

評估任務二:商業分析模擬

Business Analytics Simulation — Demand for Web-Development Courses

課程:231708 Foundation Studio — Session 3 2026

學生姓名:PoKai Huang 學號:26254793

提交日期:2026 年 5 月

資料來源:Udemy Courses Dataset(Kaggle, $n = 1,203$,已剔除缺失值)

身為一家網頁開發公司的數據分析師,本報告運用 Udemy 平台上 1,203 門網頁開發類課程的真實資料(取自 Kaggle,已剔除缺失值),分析課程價格、訂閱人數與其他特徵之間的關係,作為公司評估是否拓展至線上教育市場的決策依據。以下依序回答十一個分析問題;迴歸的虛擬變數基準組為 2011 年與「All Levels」。

問題一:描述性統計

表 1 列出六個主要變數的集中趨勢(平均數、中位數、眾數)與離散程度(標準差、最小值、最大值)。

變數	平均數	中位數	眾數	標準差	最小值	最大值
price	77.04	50.00	20.00	66.15	0.00	200.00
num_subscribers	6,635	2,430	578	14,559	19	268,923
num_reviews	357	65	16	1,573	0	27,445
num_lectures	53	32	20	63	5	779
rating	0.643	0.760	0.960	0.306	0.000	1.000
content_duration	5.59	3.00	1.00	7.24	0.50	76.50

表 1 六個主要變數的描述性統計($n = 1,203$)




圖 1 課程價格(price)的次數分布




圖 2 訂閱人數(num_subscribers)的次數分布

分布特徵:**price** 呈現右偏(平均數 77.04 高於中位數 50):多數課程定價偏低,少數高價課程拉高平均;圖 1 左端可見一群價格為 0 的免費課程。num_subscribers 則呈極端右偏——平均數 6,635 遠高於中位數 2,430,最大值高達 268,923,偏態係數約 8.4。絕大多數課程訂閱數不高,僅極少數「爆款」課程擁有龐大訂閱;這也意味平均數會被極端值嚴重拉高,中位數更能代表「典型」課程。此高度偏態預示:後續迴歸若直接使用原始數值,結果易受極端值影響(詳見問題十)。rating 則略為左偏(中位數 0.76 高於平均 0.64)。

問題二:level 與 year 的頻數分布




圖 3 課程程度(level)的頻數分布




圖 4 課程推出年份(year)的頻數分布

就課程程度而言,超過半數課程標示為「All Levels」(633 門,52.6%),其次為「Beginner Level」(422 門,35.1%);「Intermediate」與「Expert」合計不足 13%,顯示平台的網頁開發課程以「不分程度/初學者」為主。就推出年份而言,課程數由 2011 年的 5 門快速成長,2016 年達到高峰(449 門),2017 年為 224 門(資料可能僅涵蓋當年部分月份)。此趨勢反映線上網頁開發課程的供給在 2014-2016 年間急速擴張——對考慮進入市場的公司而言,意味著這是一個競爭日益激烈的紅海市場。就變數型態而言,level 屬定性(類別)變數;year 本身為數值,但本報告將其視為類別並以虛擬變數處理,而 price、num_subscribers、num_reviews、num_lectures、content_duration 與 rating 則均為定量變數。

問題三:單樣本 t 檢定 — 平均評分是否等於 65%

假設:原假設 H_0 :課程母體的平均評分等於 0.65(65%);備擇假設 H_1 :課程母體的平均評分不等於 0.65。採雙尾單樣本 t 檢定,顯著水準 5%。

結果與結論:樣本平均評分為 0.6431($n = 1,203$),檢定統計量 $t = -0.788$,自由度 = 1202, p 值 = 0.431。由於 $p = 0.431$ 遠大於 0.05,在 5% 顯著水準下無法拒絕原假設。亦即:沒有足夠的統計證據顯示課程的平均評分與 65% 有顯著差異。進一步以區間估計檢視,平均評分的 95% 信賴區間約為 [0.626, 0.660];此區間涵蓋檢定值 0.65,與上述 $p = 0.431$ 、無法拒絕原假設的結論一致。

問題四:價格與訂閱人數的相關性

預測:根據經濟學的需求法則,在其他條件不變下,價格上升應使需求量(訂閱人數)下降,因此筆者預期 price 與 num_subscribers 為負相關。

計算結果:price 與 num_subscribers 的皮爾森(Pearson)相關係數為 0.014,幾乎為零;斯皮爾曼等級相關亦僅 -0.065。資料並未呈現預期的負相關,與預測不符。




圖 5 價格與訂閱人數散佈圖(免費課程以橘點標示)

評論與可能解釋:(1) 免費課程的干擾——134 門免費課(price = 0)平均訂閱數高達 17,864,遠高於付費課的 5,227(見圖 5),這群「零價格、高訂閱」的觀測值壓平了整體的價量關係;(2) 價格內生於品質——較貴的課程往往內容更完整、講師更具經驗,品質本身會吸引訂閱,使價格的負向效果被品質的正向效果抵銷;(3) 此處的原始相關係數混合了異質課程,並未控制其他特徵。後續迴歸(問題五)即在控制這些特徵後重新檢視價量關係。

問題五:價格對訂閱人數的線性迴歸

簡單迴歸模型以 num_subscribers 為因變數、price 為唯一自變數,結果如表 2。

項目	係數	標準誤	t 值	p 值
截距 (Intercept)	6,397.99	—	—	—
price	3.077	6.351	0.48	0.628

表 2 簡單迴歸結果(因變數:num_subscribers; $R^2 = 0.0002, n = 1,203$)

多元迴歸模型再加入控制變數:課程講座數(num_lectures)、課程時長(content_duration),以及 year 與 level 的類別虛擬變數,結果如表 3。

項目	係數	標準誤	t 值	p 值
截距 (Intercept)	20,778.842	6,229.256	3.34	< 0.001
price	-4.425	6.683	-0.66	0.508
num_lectures	0.226	12.610	0.02	0.986
content_duration	300.730	108.606	2.77	0.006
level:Beginner	1,038.516	870.201	1.19	0.233
level:Expert	8,671.545	3,744.405	2.32	0.021

項目	係數	標準誤	t 值	p 值
level:Intermediate	-576.249	1,318.523	-0.44	0.662
year:2012	-6,174.282	6,954.133	-0.89	0.375
year:2013	-1,641.504	6,480.094	-0.25	0.800
year:2014	-12,845.698	6,339.825	-2.03	0.043
year:2015	-15,160.559	6,250.414	-2.43	0.015
year:2016	-17,797.350	6,238.689	-2.85	0.004
year:2017	-19,433.136	6,278.637	-3.10	0.002

表3 多元迴歸結果(因變數:num_subscribers; $R^2 = 0.108$,調整後 $R^2 = 0.099$, $n = 1,203$;基準組:2011 年、All Levels)

多元模型整體顯著(F 檢定 $p < 0.001$), R^2 為 0.108;各係數的解讀見問題六。

問題六:迴歸係數的解讀與顯著性

價格(price):簡單模型中係數為 +3.08($p = 0.628$),多元模型中為 -4.43($p = 0.508$),兩者皆不具統計顯著性。多元模型的數值意義為:在控制其他特徵後,價格每提高 1 美元,預測訂閱人數平均減少約 4.4 人——但此效果與零無顯著差異,不能斷言價格確實壓低了訂閱。

課程時長(content_duration):係數 +300.7, $p = 0.006$,在 1% 水準顯著。課程每增加 1 小時內容,預測訂閱人數平均增加約 301 人——是模型中最強且方向最穩健的正向驅動因子。

講座數(num_lectures):係數約 0.23, $p = 0.986$,完全不顯著。在已控制課程時長後,單純的講座「則數」對訂閱沒有額外解釋力。

年份虛擬變數:相對於基準年 2011,2014-2017 年的係數皆顯著為負(例如 2017 年為 -19,433, $p = 0.002$),且越近年數值越負。這反映越早推出的課程累積訂閱的時間越長,而非新課程「品質較差」。

程度虛擬變數:相對於「All Levels」,Expert Level 的係數為 +8,672($p = 0.021$)顯著為正;Beginner 與 Intermediate 則不顯著。惟 Expert 課程僅 14 門,此結果應審慎看待。

為何加入控制變數後價格係數會改變:這是遺漏變數偏誤(omitted variable bias)。課程時長同時與價格正相關(內容越多、定價越高),又與訂閱人數正相關;簡單

模型未納入課程時長,便把這部分原屬「課程時長」的正向效果錯誤地歸給了價格,使價格係數偏正(+3.08)。一旦在多元模型中控制課程時長等變數,價格係數便回落並轉為負值(-4.43),更接近其「淨」效果。

問題七:模型的解釋力

多元迴歸模型的 R^2 為 0.108,代表模型中的自變數合計只能解釋訂閱人數變異的約 10.8%,其餘約 89% 的變異未被解釋。這顯示:僅憑課程的可觀察特徵(價格、講座數、時長、年份、程度)對線上課程需求的預測能力相當有限。訂閱人數可能更取決於難以量化的因素——課程品質、講師知名度、行銷與曝光、平台演算法推薦、口碑評價等。對公司而言,這意味著不能單靠這些表面特徵準確預估一門新課程的市場表現,進入線上教育市場存在相當程度的需求不確定性。

問題八:第五題的結果是否反映因果效應?

第五題的迴歸結果不應被解讀為價格對需求的因果效應,而較可能捕捉到其他因素。主因是遺漏變數偏誤與價格的內生性:價格並非隨機指派,而是與許多未被觀測、卻同時影響訂閱人數的因素相關。

一個具體的遺漏因素是課程品質(內容完整度、製作水準、講師專業度)。高品質課程往往定價較高,同時也因品質而吸引更多訂閱;模型未納入品質,價格便成了品質的代理變數。

此推論可由一項穩健性檢查佐證(見表 4):若僅以 1,069 門付費課程估計(排除 134 門免費課),價格與訂閱人數的關係反轉為顯著正向——多元模型中價格係數變為 +27.1($p < 0.001$)。付費市場呈現「越貴、訂閱越多」,正符合「價格替品質說話」的解釋,而非真正的需求法則。因此第五題的係數混合了價格效果與品質等遺漏因素,不能視為因果效應。

指標	全部 1,203 筆	僅付費 1,069 筆
price 與訂閱的相關係數	0.014	+0.220
多元迴歸 price 係數	-4.43(不顯著)	+27.1($p < 0.001$)
對數模型 $\log(\text{price})$ 係數	-0.154($p < 0.001$)	+0.248($p < 0.001$)

表 4 穩健性檢查:全樣本 vs 僅付費樣本 — 價量關係隨樣本翻轉

問題九:最能預測需求的因素與課程建議

根據第五題的結果,對訂閱人數最具預測力的可觀察因素是課程時長 (content_duration)——它是唯一在多元模型中顯著、且方向穩定的正向驅動因子;其次,Expert 程度的課程訂閱數顯著較高,而課程的推出年份則主要反映訂閱累積的時間。價格本身並非有效的預測或操作槓桿(係數不顯著)。

若目標是確保較高的訂閱人數,筆者建議公司優先開發內容扎實、時數充足的課程,而非僅靠增加講座「則數」或單純壓低價格;亦可考慮投入較進階(Expert)的題材以做出市場區隔。同時須留意:「舊課程訂閱較多」反映的是時間累積效果,並非可立即複製的策略——新課程需要時間經營與口碑累積。

問題十:對數—對數需求函數

依公司經濟學家的建議,將問題五(含控制變數)的模型改以對數形式估計:因變數改為 $\log(\text{訂閱人數})$ 、價格自變數改為 $\log(\text{價格})$ (資料集已提供對應的對數欄位;其中價格為零的免費課程,於取對數前先加上一微小常數,以避免 $\log(0)$ 無定義)。估計結果如表 5。

項目	係數	標準誤	t 值	p 值
截距 (Intercept)	9.7488	0.5317	18.33	< 0.001
log(price)	-0.1544	0.0124	-12.44	< 0.001
num_lectures	0.0016	0.0011	1.54	0.124
content_duration	0.0217	0.0092	2.35	0.019
level:Beginner	0.0244	0.0741	0.33	0.742
level:Expert	0.0032	0.3190	0.01	0.992
level:Intermediate	0.1549	0.1123	1.38	0.168
year:2012	-0.5555	0.5925	-0.94	0.349
year:2013	-0.5918	0.5517	-1.07	0.284
year:2014	-1.1422	0.5404	-2.11	0.035
year:2015	-1.3783	0.5322	-2.59	0.010
year:2016	-1.7522	0.5311	-3.30	< 0.001
year:2017	-2.2315	0.5343	-4.18	< 0.001

表 5 對數—對數迴歸結果(因變數: $\log(\text{num_subscribers})$; $R^2 = 0.229$,調整後 $R^2 = 0.222$, $n = 1,203$)

結論是否改變:是。 $\log(\text{price})$ 的係數為 -0.154 , $p < 0.001$, 在統計上高度顯著。相較於問題五的線性模型(價格係數不顯著), 對數模型顯示價格與訂閱人數之間存在顯著的負向關係: 價格每上升 1%, 訂閱人數平均下降約 0.15% (即價格彈性約 -0.15 , 需求缺乏彈性)。

模型擬合: R^2 由線性模型的 0.108 提升至 0.229, 解釋力提高超過一倍, 顯示對數設定明顯更能配適資料。

設定是否更合適: 筆者認為對數—對數設定確實較佳。問題一已顯示價格與訂閱人數都極度右偏; 取對數可壓縮極端值、使關係更接近線性, 且係數能直接解讀為彈性, 便於商業比較。惟須提醒: 同一項穩健性檢查顯示, 僅就付費課程估計時 $\log(\text{price})$ 係數轉為 $+0.248$ ($p < 0.001$, 見表 4)。可見全樣本的 -0.15 彈性主要由「免費 vs 付費」的對比所驅動, 而非付費市場內部真正的價格反應。因此對數設定在統計上較適當, 但其係數仍非乾淨的因果彈性。




圖6 $\log(\text{價格})$ 與 $\log(\text{訂閱人數})$ 散佈圖

問題十一(挑戰題): 線性需求曲線

以問題五的多元迴歸方程, 為一門具下列特徵的課程預測訂閱人數: 50 則講座、課程時長 10 小時、2017 年推出、初級(Beginner)程度。在不同價格下的預測訂閱人數為: 價格 0 美元 $\rightarrow$ 5,403 人; 50 美元 $\rightarrow$ 5,182; 100 美元 $\rightarrow$ 4,960; 150 美元 $\rightarrow$ 4,739; 200 美元 $\rightarrow$ 4,518。將這些(訂閱人數, 價格)點相連, 即得圖 7 的線性需求曲線。




圖 7 估計的線性需求曲線(50 則講座、10 小時、2017 年、Beginner)

曲線的含義:這是一條向下傾斜的線性需求曲線,斜率為「價格每提高 1 美元、預測訂閱人數減少約 4.4 人」,需求方程約為 $Q \approx 5,403 - 4.4 \times P$ 。它表示在課程其他特徵固定下,價格越高、預測需求量越低,方向上符合需求法則。但須謹慎解讀:此斜率來自問題五中並不顯著的價格係數,因此這條曲線較適合作為「在給定特徵下的需求預測工具」,而非價格因果效果的精確度量。

結論與商業建議

綜合本次分析,對考慮拓展線上教育的公司有三點啟示。第一,課程需求高度集中且難以預測——訂閱數呈極端右偏,迴歸模型僅能解釋約 11% 的變異,公司不應期待用簡單的課程特徵準確預估新課表現,須為需求不確定性預留空間。第二,課程內容深度(時長)是最穩健的正向驅動因子,值得作為產品設計與資源投入的重點。第三,價格與需求的關係並不單純:線性模型看不出顯著效果,對數模型顯示輕微的負彈性(約 -0.15),但穩健性檢查顯示此關係主要源於免費課程,且價格與品質高度糾纏,無法視為因果。因此公司在定價決策上應同時考量「價格作為品質訊號」的效果,而非單純假設「降價即可衝高訂閱」。

最後,本分析仍有若干限制宜一併說明。資料屬單一時點的觀察性橫斷面,只能描述變數間的關聯、無法確立因果;免費課程對價量關係造成明顯干擾,使全樣本與付費樣本的結論在方向上出現反轉;加上模型僅能解釋約一到兩成的訂閱變異,課程品質、講師聲譽與行銷曝光等關鍵因素並未納入。因此上述結論較適合作為公司進入市場前的初步參考,而非精確的需求預測。

參考文獻

andrewmvd. (2020). Udemmy courses [Data set]. Kaggle.

<https://www.kaggle.com/datasets/andrewmvd/udemy-courses>

University of Technology Sydney. (2026). 231708 Foundation Studio, Unit 2: Business statistics and linear regression [Course materials].